

Automatyczna klasyfikacja danych motion capture przy użyciu sieci LSTM

Prezentacja wyników projektu

Tymoteusz Mucha, Jakub Szafarczyk, Konrad Wnuk


15 czerwca 2026



**Politechnika
Śląska**

Cel projektu i dane

- Cel: klasyfikacja sekwencji ruchu 3D z danych motion capture.
- Dane: Riglet et al. 2024, 30 uczestników, 63 markery, Vicon 100 Hz.
- Wejście: współrzędne XYZ markerów w kolejnych klatkach.
- Wykorzystano pliki CSV z katalogów **Post_Process**.



Przetwarzanie danych

- wczytanie plików CSV,
- centrowanie markerów względem miednicy,
- standaryzacja cech,
- podział na okna czasowe,
- podział `train/val/test`.

Model LSTM

- analizuje zależności między klatkami,
- wejście: (`window`, `n_features`),
- wyjście: klasyfikacja softmax,
- agregacja okien do wyniku nagrania przez modę.

- **`gait_type`** – rozpoznanie typu ruchu, np. chód wolny, szybki lub bieg.
- **`sex`** – rozpoznanie płci uczestnika.
- **`participant_id`** – identyfikacja konkretnego uczestnika.

Najważniejsze założenie

Model nie dostaje gotowych cech biomechanicznych – uczy się wzorców bezpośrednio z sekwencji położeń markerów.

Model	Okno	Krok	Warstwy LSTM
w5-L15	5	5	15
w10-L15x2	10	5	15, 15
w20-L15x3	20	10	15, 15, 15
w20-L32	20	10	32
w50-L32	50	25	32
w50-L64	50	25	64
w100-L64x32-D32	100	50	64, 32 + Dense 32

Skala

7 konfiguracji $\times$ 3 zadania = **21 wytrenowanych modeli**, optymalizator Adam, lr = 0,001.

- Wyniki liczone na dwóch poziomach:
 - **okno** – klasyfikacja pojedynczego fragmentu sekwencji,
 - **nagranie** – jedna decyzja po agregacji predykcji okien.
- Główna metryka rankingowa: **F1-macro**.
- Dodatkowo analizowano accuracy, precision, recall i macierze pomyłek.

Dlaczego F1-macro?

Metryka traktuje klasy równoważnie, więc lepiej pokazuje jakość klasyfikacji przy nierównych licznościach klas.


Podsumowanie wyników

Zadanie	Najlepsze okno	Najlepsze nagranie	Max F1
Chód	w50-L64: 76,3%	w20-L32: 84,0%	~0,84
Płeć	~100%	100%	1,00
ID	w50-L64: 99,8%	w10-L15x2 / w50-L64: 100%	1,00

Wniosek


w50-L64 jest najbezpieczniejszym modelem uniwersalnym, ale dla klasyfikacji całych nagrań typu chodu najlepszy był **w20-L32**.

Wyniki: typ chodu




Najlepszy wynik na poziomie nagrania: 84,0% dla w20-L32.

Wyniki: płeć



Wszystkie konfiguracje osiągnęły wynik bliski 100%.

Wyniki: identyfikacja uczestnika




Najlepsze modele osiągnęły 100% na poziomie nagrania.

Interpretacja: możliwy overfitting


- Wyniki 100% dla płci i ID uczestnika są bardzo wysokie i wymagają ostrożnej interpretacji.
- Podział `within_participant` powoduje, że dane tego samego uczestnika występują w treningu i teście.
- Model może uczyć się sygnatury uczestnika lub nagrania, np. proporcji ciała, ustawienia markerów albo charakterystycznego wzorca ruchu.
- Do mocniejszej weryfikacji potrzebny byłby podział `participant_holdout`.

Macierze pomyłek

Typ chodu




Płeć



ID uczestnika

Recording Confusion Matrix



- LSTM skutecznie klasyfikuje sekwencje motion capture na podstawie okien czasowych.
- Najtrudniejszym zadaniem było rozpoznawanie typu chodu.
- Agregacja okien do poziomu nagrania zwykle poprawiała wynik, ale nie zawsze.
- **w50-L64** był najbardziej uniwersalną konfiguracją.
- Kolejny krok: walidacja na nowych uczestnikach i sprawdzenie odporności modeli na zmianę sesji.

Artykuł referencyjny

- da Silva, R., Ondřej, J., Smolic, A.
Using LSTM for Automatic Classification of Human Motion Capture Data.
VISIGRAPP 2019, s. 236–243.
DOI: 10.5220/0007349902360243

Zbiór danych

- Riglet, L. i in.
3D motion analysis dataset of healthy young adult volunteers walking and running on overground and treadmill.
Scientific Data 11, 556 (2024).