

Automatyczna klasyfikacja danych motion capture przy użyciu sieci LSTM

Prezentacja wyników projektu

Tymoteusz Mucha, Jakub Szafarczyk, Konrad Wnuk

14 czerwca 2026





**Politechnika
Śląska**

Czym jest motion capture

- Rejestracja ruchu w przestrzeni 3D.
- Wynik: sekwencja pozycji markerów lub stawów w czasie.
- Każda klatka – „szkielet” opisany wektorem współrzędnych.
- Technologie: optyczne (Vicon), IMU, mechaniczne, magnetyczne.
- Zastosowania: animacja, biomechanika, sport, rehabilitacja.

Sekwencja klatek chodu



Sieć LSTM – opis sieci

- LSTM = Long Short-Term Memory, wariant rekurencyjnej sieci neuronowej.
- Zaprojektowana do uczenia się zależności w sekwencjach.
- Rozwiązuje problem zanikającego gradientu klasycznych RNN.
- Trzy bramki sterują przepływem informacji w komórce:
 - **forget** – co wyrzucić z pamięci,
 - **input** – co dopisać,
 - **output** – co wypuścić dalej.

Dlaczego LSTM dla mocap

ruch to sekwencja czasowa – LSTM modeluje relacje między klatkami w oknie czasowym i wykorzystuje je do klasyfikacji

Riglet et al., 2024 – Scientific Data (Nature)

„3D motion analysis dataset of healthy young adult volunteers walking and running on overground and treadmill”

- 30 zdrowych ochotników (28 ± 6 lat), 63 markery (CGM 2.5).
- System Vicon, 18 kamer, 100 Hz, dwie sesje na uczestnika.
- Chód: 3 prędkości; bieg: 2 prędkości; overground i bieżnia.
- W projekcie wykorzystano pliki **CSV** (Post_Process), nie pliki C3D.
- Struktura:
data/<participant_id>/Session*/<protokół>/<próba>/Post_Process/*.csv.
- Dodatkowo metadata.xlsx z danymi uczestników (płeć, sesja itd.).

Pipeline przetwarzania danych

- Wczytanie wszystkich plików CSV z Post_Process dla każdego uczestnika i sesji.
- **Centrowanie** współrzędnych markerów względem miednicy (usunięcie globalnego przemieszczenia).
- **Standaryzacja** cech (StandardScaler).
- Podział sygnału na **okna czasowe** o długości window z krokiem step.
- Podział train/val/test typu **within_participant** – próby każdego uczestnika trafiają proporcjonalnie do każdego zbioru.

Dlaczego within_participant

każde zadanie (także participant_id) ma reprezentację wszystkich klas zarówno w treningu, jak i w teście

Trzy zadania klasyfikacji

- `gait_type` – typ ruchu, np. `walk_slow`, `walk_fast`, `run_comfortable`.
- `sex` – płeć uczestnika.
- `participant_id` – identyfikacja konkretnego uczestnika.

Wejście do sieci:

- wektor współrzędnych XYZ markerów (po centrowaniu i standaryzacji),
- tensor (`window`, `n_features`),
- wyjście: rozkład prawdopodobieństwa nad klasami (softmax, one-hot).

Siedem konfiguracji modeli (preset presentation)

Nazwa	Okno	Krok	Warstwy LSTM	Dropout
win5_lstm15	5	5	15	0.20
win10_lstm15x15	10	5	15, 15	0.20
win20_lstm15x15x15	20	10	15, 15, 15	0.25
win20_lstm32	20	10	32	0.30
win50_lstm32	50	25	32	0.30
win50_lstm64	50	25	64	0.30
win100_lstm64x32_dense32	100	50	64, 32 (+Dense 32)	0.30

Skala eksperymentu

7 konfiguracji $\times$ 3 zadania = **21 wytrenowanych modeli**, optymalizator Adam (lr = 0,001)

Kod – skrypt treningowy

`scripts/train_lstm_experiments.py`

- Dla każdej konfiguracji i każdego zadania:
 - wczytuje dane, buduje okna i podział train/val/test,
 - budowa modelu: stacked LSTM + (opcjonalnie Dense) + warstwa wyjściowa softmax,
 - trening z EarlyStopping / checkpointami – zapis `best_model.keras` (wg `val_loss`) i `last_model.keras`,
 - ewaluacja na poziomie **okna** oraz **całego nagrania** (agregacja predykcji okien przez modę).
- Wyniki zapisywane do `models/lstm_experiments/<run>/`:
`history.csv`, `metrics.json`, `*_predictions.csv`,
`*_confusion_matrix.csv/.png`.

`scripts/summarize_lstm_results.py` – zbiera wyniki wszystkich runów, tworzy `evaluation_summary.csv`, `best_runs_top3.csv` oraz wykresy porównawcze.

- **Poziom okna** – predykcja dla pojedynczego okna czasowego.
- **Poziom nagrania** – agregacja predykcji okien danego pliku przez **model** -> jedna finalna decyzja na nagranie.
- Metryki: accuracy, precision, recall, F1-macro, macierz pomyłek.
- F1-macro jako główna metryka rankingowa – odporna na nierównowagę klas (istotne zwłaszcza dla participant_id).

Schemat agregacji okno -> nagranie


każde nagranie dzielone jest na okna -> model klasyfikuje każde okno -> wynik nagrania = klasa najczęściej przewidywana wśród jego okien

- Najtrudniejsze zadanie i jedyne z realną rywalizacją modeli.
- Poziom nagrania: trzy konfiguracje remisują w okolicy 83–84%:
 - win20_lstm32 – **84,0%** (najlepszy),
 - win10_lstm15x15 – 83,7%,
 - win50_lstm64 – 83,2%.
- Poziom okna: zdecydowanie wygrywa win50_lstm64 – 76,3%.
- Wybór modelu zależy od jednostki decyzji: całe nagranie -> win20_lstm32; pojedyncze okno (np. real-time) -> win50_lstm64.

Wyniki – typ chodu (porównanie modeli)


Rozpoznawanie TYPU CHODU (gait_type)

Najtrudniejsze zadanie — tu wybór modelu naprawdę robi różnicę



★ = najlepszy model na poziomie nagrania

Wyniki – typ chodu (macierz pomyłek)




- Wszystkie 7 konfiguracji, łącznie z najmniejszą (win5_lstm15), osiągają **accuracy / F1-macro $\approx 100\%$** .
- Zarówno na poziomie okna, jak i całego nagrania.
- Różnice anatomiczne między płciami są na tyle wyraźne, że nawet bardzo prosty model je wychwytuje.

Wyniki – rozpoznawanie płci (porównanie modeli)


Rozpoznawanie PŁCI (sex)

Zadanie trywialne — wszystkie modele praktycznie idealne




Najniższy wynik to poziom okna 0.99984 (win50/32). Poziom nagrania = 1.000 dla KAŻDEGO modelu — brak różnic.

Wyniki – rozpoznawanie płci (macierz pomyłek)




- Obraz **dwubiegunowy**: część konfiguracji prawie idealna, część „zapada się”.
- win10_lstm15x15 i win50_lstm64: **100% accuracy / F1** na poziomie nagrania.
- Słabsze modele (win5_lstm15, win20_lstm32, win50_lstm32): spadek do ~75% na nagraniu.
- Ciekawy efekt: dla słabych modeli wynik na poziomie **okna bywa wyższy** niż na poziomie nagrania (win50_lstm32: 84,4% okno vs 75,6% nagranie) – błędy nie są losowe, całe nagrania trafiają do złej klasy.

Wyniki – identyfikacja uczestnika (porównanie modeli)



Wyniki – identyfikacja uczestnika (macierz pomyłek)



Podsumowanie wyników

Zadanie	Najlepszy (okno)	Najlepszy (nagranie)	Max F1
typ chodu	win50_lstm64 – 76,3%	win20_lstm32 – 84,0%	~0,84
płeć	dowolny – ~100%	dowolny – 100%	1,00
ID uczestnika	win50_lstm64 – 99,8%	win10_lstm15x15 / win50_lstm64 – 100%	1,00

Wniosek praktyczny

win50_lstm64 jest najbezpieczniejszym wyborem „uniwersalnym” – wygrywa lub remisuje na poziomie okna we wszystkich trzech zadaniach.

Hipoteza: overfitting dla sex i participant_id

- Oczekiwania (z literatury / planu projektu): typ chodu $>95\%$, płeć 80–90%, identyfikacja uczestnika 70–85%.
- Rzeczywiste wyniki: typ chodu $\sim 87\%$ accuracy (84% F1), płeć i ID uczestnika – **100%**.
- Tak wysoki wynik dla zadań „trudniejszych z definicji” jest podejrzany i może sugerować overfitting
- Możliwe przyczyny:
 - podział within_participant – okna z tego samego nagrania (bardzo podobne) trafiają zarówno do train, jak i do test,
 - sieć może uczyć się „sygnatury” konkretnego nagrania/uczestnika (np. wzrost, proporcje ciała widoczne w pozycjach markerów) zamiast uogólnionego wzorca,

- Sieci LSTM dobrze radzą sobie z klasyfikacją danych mocap na podstawie okien czasowych współrzędnych markerów.
- Agregacja okno -> nagranie zwykle poprawia wynik, ale nie zawsze – przy słabych modelach może go pogorszyć.
- Wynik silnie zależy od zadania: typ chodu jest istotnie trudniejszy niż płeć czy identyfikacja uczestnika.
- Najlepszy „uniwersalny” model w naszych eksperymentach: win50_lstm64.
- 100% trafności dla płci i ID uczestnika wymaga dalszej weryfikacji (np. podział `participant_holdout`, walidacja na zupełnie nowych uczestnikach).

Artykuł referencyjny:

- da Silva, R., Ondřej, J., Smolic, A.
Using LSTM for Automatic Classification of Human Motion Capture Data.
VISIGRAPP 2019, s. 236–243.
DOI: 10.5220/0007349902360243

Zbiór danych:

- Riglet, L. i in.
3D motion analysis dataset of healthy young adult volunteers walking and running on overground and treadmill.
Scientific Data 11, 556 (2024).
<https://www.nature.com/articles/s41597-024-03420-y>