

Automatyczna klasyfikacja danych motion capture przy użyciu sieci LSTM

Prezentacja wyników projektu

Tymoteusz Mucha, Jakub Szafarczyk, Konrad Wnuk


14 czerwca 2026



**Politechnika
Śląska**

Motion capture i dane wejściowe

- Motion capture rejestruje ruch 3D jako sekwencję pozycji markerów/stawów w czasie.
- Każda klatka opisuje „szkielet” wektorem współrzędnych.
- Dane: Riglet et al. 2024, 30 uczestników, 63 markery, Vicon 100 Hz.
- Wykorzystano pliki CSV z katalogów **Post_Process**.



Pipeline przetwarzania

- Wczytanie plików CSV dla uczestników i sesji.
- Centrowanie markerów względem miednicy.
- Standaryzacja cech.
- Podział sygnału na okna czasowe `window` z krokiem `step`.
- Podział `train/val/test` typu `within_participant`.

Model LSTM i zadania klasyfikacji

- LSTM modeluje zależności czasowe między kolejnymi klatkami ruchu.
- Wejście: tensor (**window**, **n_features**) ze współrzędnymi XYZ markerów.
- Wyjście: klasyfikacja przez warstwę softmax.

Zadania klasyfikacji:

- **gait_type** – typ ruchu,
- **sex** – płeć uczestnika,
- **participant_id** – identyfikacja uczestnika.

Siedem konfiguracji modeli (preset presentation)

Nazwa	Okno	Krok	Warstwy LSTM	Dropout
win5_lstm15	5	5	15	0.20
win10_lstm15x15	10	5	15, 15	0.20
win20_lstm15x15x15	20	10	15, 15, 15	0.25
win20_lstm32	20	10	32	0.30
win50_lstm32	50	25	32	0.30
win50_lstm64	50	25	64	0.30
win100_lstm64x32_dense32	100	50	64, 32 (+Dense 32)	0.30

Skala eksperymentu

7 konfiguracji $\times$ 3 zadania = **21 wytrenowanych modeli**, optymalizator Adam (lr = 0,001)

`scripts/train_lstm_experiments.py`

- Dla każdej konfiguracji i każdego zadania:
 - wczytuje dane, buduje okna i podział train/val/test,
 - budowa modelu: stacked LSTM + (opcjonalnie Dense) + warstwa wyjściowa softmax,
 - trening z `EarlyStopping` / checkpointami – zapis `best_model.keras` (wg `val_loss`) i `last_model.keras`,
 - ewaluacja na poziomie **okna** oraz **całego nagrania** (agregacja predykcji okien przez modę).
- Wyniki zapisywane do `models/lstm_experiments/<run>/: history.csv, metrics.json, *_predictions.csv, *_confusion_matrix.csv/.png`.


- **Poziom okna** – predykcja dla pojedynczego okna czasowego.
- **Poziom nagrania** – agregacja predykcji okien danego pliku przez **model** -> jedna finalna decyzja na nagranie.
- Metryki: **accuracy**, **precision**, **recall**, **F1-macro**, macierz pomyłek.
- **F1-macro** jako główna metryka rankingowa – odporna na nierównowagę klas (istotne zwłaszcza dla **participant_id**).

Schemat agregacji okno -> nagranie


każde nagranie dzielone jest na okna -> model klasyfikuje każde okno -> wynik nagrania = klasa najczęściej przewidywana wśród jego okien

- Najtrudniejsze zadanie i jedyne z realną rywalizacją modeli.
- Poziom nagrania: trzy konfiguracje remisują w okolicy 83–84%:
 - `win20_lstm32` – 84,0% (najlepszy),
 - `win10_lstm15x15` – 83,7%,
 - `win50_lstm64` – 83,2%.
- Poziom okna: zdecydowanie wygrywa `win50_lstm64` – 76,3%.
- Wybór modelu zależy od jednostki decyzji: całe nagranie -> `win20_lstm32`; pojedyncze okno (np. real-time) -> `win50_lstm64`.

Wyniki – typ chodu (porównanie modeli)



Wyniki – typ chodu (macierz pomyłek)




- Wszystkie 7 konfiguracji, łącznie z najmniejszą (`win5_lstm15`), osiągają **accuracy / F1-macro $\approx 100\%$** .
- Zarówno na poziomie okna, jak i całego nagrania.
- Różnice anatomiczne między płciami są na tyle wyraźne, że nawet bardzo prosty model je wychwytuje.

Wyniki – rozpoznawanie płci (porównanie modeli)


Rozpoznawanie Płci (sex)

Zadanie trywialne — wszystkie modele praktycznie idealne



Najniższy wynik to poziom okna 0.99984 (win50/32). Poziom nagrania = 1.000 dla KAŻDEGO modelu — brak różnic.


Wyniki – rozpoznawanie płci (macierz pomyłek)




Wyniki – identyfikacja uczestnika

- Obraz **dwubiegunowy**: część konfiguracji prawie idealna, część „zapada się”.
- **win10_lstm15x15** i **win50_lstm64**: 100% accuracy / F1 na poziomie nagrania.
- Słabsze modele (**win5_lstm15**, **win20_lstm32**, **win50_lstm32**): spadek do ~75% na nagraniu.
- Ciekawy efekt: dla słabych modeli wynik na poziomie **okna bywa wyższy** niż na poziomie nagrania (**win50_lstm32**: 84,4% okno vs 75,6% nagranie) – błędy nie są losowe, całe nagrania trafiają do złej klasy.

Wyniki – identyfikacja uczestnika (porównanie modeli)



Wyniki – identyfikacja uczestnika (macierz pomyłek)



Podsumowanie wyników

Zadanie	Okno	Nagranie	F1
Chód	w50-L64: 76,3%	w20-L32: 84,0%	~0,84
Płeć	~100%	100%	1,00
ID	w50-L64: 99,8%	w10-L15x2 / w50-L64: 100%	1,00

Wniosek praktyczny

`win50_lstm64` jest najbezpieczniejszym wyborem „uniwersalnym” – wygrywa lub remisuje na poziomie okna we wszystkich trzech zadaniach.

Hipoteza: overfitting dla `sex` i `participant_id`

- Oczekiwania (z literatury / planu projektu): typ chodu $>95\%$, płeć 80–90%, identyfikacja uczestnika 70–85%.
- Rzeczywiste wyniki: typ chodu $\sim 87\%$ accuracy (84% F1), płeć i ID uczestnika – **100%**.
- Tak wysoki wynik dla zadań „trudniejszych z definicji” jest podejrzany i może sugerować overfitting
- Możliwe przyczyny:
 - podział `within_participant` – okna z tego samego nagrania (bardzo podobne) trafiają zarówno do train, jak i do test,
 - sieć może uczyć się „sygnatury” konkretnego nagrania/uczestnika (np. wzrost, proporcje ciała widoczne w pozycjach markerów) zamiast uogólnionego wzorca,

- Sieci LSTM dobrze radzą sobie z klasyfikacją danych mocap na podstawie okien czasowych współrzędnych markerów.
- Agregacja okno -> nagranie zwykle poprawia wynik, ale nie zawsze – przy słabych modelach może go pogorszyć.
- Wynik silnie zależy od zadania: typ chodu jest istotnie trudniejszy niż płeć czy identyfikacja uczestnika.
- Najlepszy „uniwersalny” model w naszych eksperymentach: `win50_lstm64`.
- 100% trafności dla płci i ID uczestnika wymaga dalszej weryfikacji (np. podział `participant_holdout`, walidacja na zupełnie nowych uczestnikach).

Artykuł referencyjny:

- da Silva, R., Ondřej, J., Smolic, A.
Using LSTM for Automatic Classification of Human Motion Capture Data.
VISIGRAPP 2019, s. 236–243.
DOI: **10.5220/0007349902360243**

Zbiór danych:

- Riglet, L. i in.
3D motion analysis dataset of healthy young adult volunteers walking and running on overground and treadmill.
Scientific Data 11, 556 (2024).
<https://www.nature.com/articles/s41597-024-03420-y>