

Skrypt do prezentacji projektu

Automatyczna klasyfikacja danych motion capture przy użyciu sieci LSTM

1. Ogólny plan prezentacji

Prezentacja dotyczy klasyfikacji danych motion capture, czyli danych opisujących ruch człowieka w przestrzeni 3D. Naszym celem było sprawdzenie, czy sieć LSTM potrafi rozpoznawać wzorce ruchu na podstawie sekwencji położenia markerów.

W projekcie klasyfikowaliśmy trzy rzeczy:

1. typ ruchu, czyli `gait_type`,
2. płeć uczestnika, czyli `sex`,
3. konkretnego uczestnika, czyli `participant_id`.

Najważniejsze pojęcia, które trzeba umieć dobrze wyjaśnić:

- czym jest motion capture,
 - czym jest okno czasowe,
 - czym jest krok okna,
 - jak działa LSTM,
 - jak przebiega trening sieci,
 - czym jest F1-macro,
 - czym różni się wynik na poziomie okna od wyniku na poziomie nagrania,
 - co pokazuje macierz pomyłek,
 - dlaczego wyniki 100% dla płci i ID trzeba interpretować ostrożnie.
-

2. Podział prezentacji na 3 role

Rola 1 — Wprowadzenie, dane, pipeline i LSTM

Zakres slajdów:

1. Strona tytułowa
2. Cel projektu i dane
3. Pipeline i model
4. Zadania klasyfikacji

Główna odpowiedzialność:

Ta osoba wyjaśnia, co było celem projektu, czym są dane motion capture, jak dane zostały przygotowane oraz dlaczego wybraliśmy LSTM. Powinna umieć dokładnie opowiedzieć, czym jest LSTM i dlaczego pasuje do danych sekwencyjnych.

Rola 2 — Eksperyment, trenowanie i ewaluacja

Zakres slajdów:

1. Eksperyment
2. Ewaluacja
3. Podsumowanie wyników

Główna odpowiedzialność:

Ta osoba tłumaczy konfiguracje modeli, parametry takie jak okno, krok, warstwy LSTM, proces treningu, metryki oceny oraz różnicę między oceną na poziomie okna i nagrania.

Rola 3 — Wyniki, macierze pomyłek, overfitting i wnioski

Zakres slajdów:

1. Wyniki: typ chodu
2. Wyniki: płeć
3. Wyniki: identyfikacja uczestnika
4. Interpretacja: możliwy overfitting
5. Macierze pomyłek — typ chodu i płeć
6. Macierze pomyłek — ID uczestnika
7. Wnioski
8. Literatura i źródła

Główna odpowiedzialność:

Ta osoba omawia wyniki, wykresy, macierze pomyłek, możliwy overfitting oraz końcowe wnioski. Powinna umieć odpowiedzieć, co wynika z wyników i jakie są ograniczenia eksperymentu.

3. Skrypt slajd po slajdzie

Slajd 1 — Strona tytułowa

Co powiedzieć

Dzień dobry. Nasz projekt dotyczy automatycznej klasyfikacji danych motion capture przy użyciu sieci LSTM.

Pracowaliśmy na danych opisujących ruch człowieka w przestrzeni 3D. Są to sekwencje położenia markerów umieszczonych na ciele uczestników. Na podstawie tych sekwencji próbowaliśmy rozpoznawać typ ruchu, płeć uczestnika oraz konkretnego uczestnika.

W projekcie chcieliśmy sprawdzić, czy model sekwencyjny, taki jak LSTM, potrafi wychwycić charakterystyczne wzorce ruchu w danych motion capture.

Najważniejsze rzeczy do powiedzenia

- Temat: klasyfikacja danych motion capture.
- Model: LSTM.
- Dane są sekwencyjne, więc naturalnie pasują do sieci rekurencyjnych.
- Klasyfikowaliśmy trzy zadania: typ chodu/ruchu, płeć, ID uczestnika.

Możliwe pytania i odpowiedzi

Pytanie: Dlaczego to jest temat z wizji komputerowej?

Odpowiedź:

Ponieważ analizujemy dane przestrzenno-czasowe opisujące ruch człowieka. Nie pracujemy bezpośrednio na obrazie RGB, ale na danych motion capture, które są wynikiem komputerowego śledzenia pozycji markerów w przestrzeni 3D. Jest to więc problem analizy ruchu i rozpoznawania wzorców ruchowych.

Pytanie: Dlaczego nie użyliście klasycznej sieci CNN?

Odpowiedź:

CNN lepiej sprawdza się przy danych obrazowych lub siatkowych. Tutaj mamy sekwencję czasową współrzędnych markerów. Dlatego bardziej naturalny był model sekwencyjny, taki jak LSTM, który analizuje zależności między kolejnymi klatkami ruchu.

Slajd 2 — Cel projektu i dane

Co powiedzieć

Celem projektu była klasyfikacja sekwencji ruchu 3D z danych motion capture.

Motion capture polega na rejestrowaniu ruchu człowieka w przestrzeni. W naszym przypadku dane składają się z pozycji markerów umieszczonych na ciele uczestnika. Każda klatka nagrania zawiera współrzędne XYZ markerów, czyli informację, gdzie dany marker znajduje się w przestrzeni.

Pracowaliśmy na zbiorze danych Riglet et al. z 2024 roku. Zbiór obejmuje 30 zdrowych uczestników, 63 markery oraz nagrania wykonane systemem Vicon z częstotliwością 100 Hz. Oznacza to, że w każdej sekundzie mamy 100 klatek ruchu.

W projekcie wykorzystywaliśmy pliki CSV z katalogów `Post_Process`. Nie pracowaliśmy bezpośrednio na surowych plikach C3D, tylko na już przetworzonych danych tabelarycznych.

Na slajdzie widać przykład sekwencji chodu. To pokazuje, że pojedyncze nagranie jest ciągiem kolejnych pozycji ciała w czasie.

Najważniejsze rzeczy do powiedzenia

- Motion capture = rejestracja ruchu w 3D.
- Jedna klatka = pozycje markerów.
- Całe nagranie = sekwencja klatek.
- Dane mają charakter czasowy.
- 100 Hz oznacza 100 klatek na sekundę.
- Model dostaje współrzędne markerów, a nie gotowe opisy ruchu.

Możliwe pytania i odpowiedzi

Pytanie: Co dokładnie było wejściem do modelu?

Odpowiedź:

Wejściem były sekwencje współrzędnych XYZ markerów. Dla każdej klatki mieliśmy wiele cech opisujących położenie markerów, a następnie takie klatki były grupowane w okna czasowe.

Pytanie: Czy model widział obraz człowieka?

Odpowiedź:

Nie. Model nie analizował obrazu z kamery. Analizował numeryczne dane motion capture, czyli współrzędne markerów w przestrzeni 3D.

Pytanie: Co oznacza 63 markery?

Odpowiedź:

To liczba punktów śledzonych na ciele uczestnika. Każdy marker ma współrzędne X, Y i Z, więc dla jednej klatki mamy dużo cech opisujących pozycję ciała.

Slajd 3 — Pipeline i model

Co powiedzieć

Na tym slajdzie pokazujemy ogólny pipeline przetwarzania danych oraz modelu.

Najpierw wczytywaliśmy pliki CSV dla uczestników i sesji. Następnie wykonywaliśmy centrowanie markerów względem miednicy. Chodziło o to, żeby ograniczyć wpływ globalnego położenia osoby w przestrzeni. Interesował nas przede wszystkim wzorec ruchu ciała, a nie to, w którym miejscu laboratorium znajdował się uczestnik.

Potem wykonywaliśmy standaryzację cech. Oznacza to przeskalowanie danych tak, aby cechy miały porównywalną skalę. Jest to ważne dla trenowania sieci neuronowych, bo cechy o dużych wartościach liczbowych mogłyby zdominować proces uczenia.

Następnie dzieliśmy sygnał na okna czasowe. Okno to fragment sekwencji, na przykład 20, 50 albo 100 kolejnych klatek. Model LSTM dostawał właśnie takie okno jako pojedynczy przykład wejściowy.

Po stronie modelu wykorzystaliśmy LSTM. LSTM analizuje zależności między kolejnymi klatkami w oknie. Na końcu model zwraca rozkład prawdopodobieństwa po klasach przez warstwę softmax.

Dokładne wyjaśnienie LSTM

LSTM, czyli Long Short-Term Memory, to specjalny typ rekurencyjnej sieci neuronowej. Sieci rekurencyjne są zaprojektowane do pracy z sekwencjami, czyli z danymi, gdzie kolejność elementów ma znaczenie.

W zwykłej sieci neuronowej każdy przykład jest traktowany niezależnie. Natomiast w LSTM model analizuje dane krok po kroku. Dla każdego momentu czasowego, czyli dla każdej klatki lub elementu sekwencji, LSTM bierze aktualne wejście oraz informację zapamiętaną z poprzednich kroków.

Najważniejszą ideą LSTM jest komórka pamięci. Ta pamięć pozwala modelowi przechowywać informacje z wcześniejszych fragmentów sekwencji. Dzięki temu model może rozpoznać nie tylko pozycję ciała w jednej klatce, ale również sposób, w jaki pozycja zmienia się w czasie.

LSTM ma trzy główne bramki:

1. **Forget gate**, czyli bramka zapominania. Decyduje, które informacje z pamięci należy usunąć.
2. **Input gate**, czyli bramka wejściowa. Decyduje, które nowe informacje dopisać do pamięci.
3. **Output gate**, czyli bramka wyjściowa. Decyduje, jaka część pamięci zostanie przekazana dalej jako wynik dla danego kroku.

W naszym przypadku LSTM analizuje kolejne klatki ruchu i uczy się, które zmiany położeń markerów są ważne dla rozpoznania klasy.

Najważniejsze rzeczy do powiedzenia

- Pipeline: CSV → centrowanie → standaryzacja → okna czasowe → LSTM → klasyfikacja.
- Centrowanie usuwa wpływ globalnego przesunięcia.
- Standaryzacja ułatwia uczenie.
- LSTM nadaje się do sekwencji.
- LSTM ma pamięć i bramki.
- Model klasyfikuje całe okno czasowe.

Możliwe pytania i odpowiedzi

Pytanie: Po co centrowaliśmy dane względem miednicy?

Odpowiedź:

Żeby model skupiał się na ruchu ciała, a nie na globalnym położeniu uczestnika w przestrzeni. Gdyby jedna osoba była przesunięta bardziej w lewo lub prawo w układzie współrzędnych, model mógłby traktować to jako istotną cechę, mimo że nie opisuje ona samego wzorca chodu.

Pytanie: Co daje standaryzacja?

Odpowiedź:

Standaryzacja wyrównuje skalę cech. Dzięki temu sieć uczy się stabilniej, a cechy o większych wartościach liczbowych nie dominują nad pozostałymi.

Pytanie: Dlaczego LSTM jest dobry do motion capture?

Odpowiedź:

Ponieważ motion capture jest sekwencją czasową. Dla rozpoznania ruchu ważne jest nie tylko to, gdzie znajdują się markery w jednej klatce, ale też jak zmieniają swoje położenie w kolejnych klatkach. LSTM potrafi modelować takie zależności czasowe.

Slajd 4 — Zadania klasyfikacji

Co powiedzieć

W projekcie rozwiązywaliśmy trzy zadania klasyfikacji.

Pierwsze zadanie to `gait_type`, czyli rozpoznawanie typu ruchu. Chodziło na przykład o odróżnienie chodu wolnego, chodu szybkiego lub biegu.

Drugie zadanie to `sex`, czyli rozpoznawanie płci uczestnika na podstawie wzorca ruchu i danych markerów.

Trzecie zadanie to `participant_id`, czyli identyfikacja konkretnego uczestnika. To znaczy, że model miał rozpoznać, do której osoby należy dana sekwencja ruchu.

Ważne jest to, że model nie dostawał ręcznie zaprojektowanych cech biomechanicznych. Nie mówiliśmy mu wprost, jaka jest długość kroku, kąt w stawie albo prędkość kończyny. Model uczył się bezpośrednio z sekwencji współrzędnych markerów.

Najważniejsze rzeczy do powiedzenia

- Były trzy zadania klasyfikacji.
- `gait_type` było najbardziej naturalnym zadaniem ruchowym.
- `sex` i `participant_id` mogą być mocno związane z anatomią i indywidualnym stylem ruchu.
- Model uczył się bezpośrednio z danych, bez gotowych cech biomechanicznych.

Możliwe pytania i odpowiedzi

Pytanie: Czy identyfikacja uczestnika nie jest za łatwa, jeśli model widzi proporcje ciała?

Odpowiedź:

Tak, to jest ważna uwaga. Wysokie wyniki dla `participant_id` mogą wynikać z tego, że model uczy

się indywidualnych cech osoby, takich jak proporcje ciała, sposób ustawienia markerów albo charakterystyczny styl ruchu. Dlatego ten wynik trzeba interpretować ostrożnie.

Pytanie: Które zadanie było najtrudniejsze?

Odpowiedź:

Najtrudniejsze było rozpoznawanie typu chodu, czyli `gait_type`. Wyniki były tam wyraźnie niższe niż dla płci i identyfikacji uczestnika.

Slajd 5 — Eksperyment

Co powiedzieć

Na tym slajdzie pokazujemy konfiguracje modeli, które testowaliśmy.

Każda konfiguracja różniła się trzema głównymi parametrami: długością okna, krokiem oraz strukturą warstw LSTM.

Okno oznacza liczbę kolejnych klatek przekazywanych do modelu jako jeden przykład. Na przykład okno równe 50 oznacza, że model analizuje fragment obejmujący 50 kolejnych klatek. Ponieważ dane mają częstotliwość 100 Hz, 50 klatek odpowiada około 0,5 sekundy ruchu.

Krok oznacza przesunięcie między kolejnymi oknami. Jeśli okno ma długość 50, a krok 25, to następne okno zaczyna się 25 klatek później. Oznacza to, że okna częściowo na siebie zachodzą.

Warstwy LSTM określają złożoność modelu. Na przykład `L64` oznacza jedną warstwę LSTM z 64 jednostkami. `L15x2` oznacza dwie warstwy LSTM po 15 jednostek. Większa liczba jednostek lub warstw oznacza większą pojemność modelu, ale też większe ryzyko przeuczenia.

Łącznie przetestowaliśmy 7 konfiguracji dla 3 zadań, czyli 21 wytrenowanych modeli.

Proces trenowania modelu

Proces trenowania wyglądał następująco:

1. Najpierw dane były dzielone na okna czasowe.
2. Każde okno dostawało etykietę klasy, na przykład typ ruchu albo ID uczestnika.
3. Model wykonywał predykcję dla okna.
4. Wynik predykcji był porównywany z prawdziwą etykietą.
5. Obliczana była funkcja straty, na przykład categorical cross-entropy.
6. Następnie przez propagację wsteczną aktualizowano wagi modelu.
7. Optymalizator Adam dobierał, jak mocno zmienić parametry.
8. Proces powtarzał się przez kolejne epoki.
9. Na zbiorze walidacyjnym sprawdzano, czy model nadal się poprawia.
10. Zapisywano najlepszy model według wyniku walidacyjnego.

Czyli model nie był programowany ręcznie regułami typu „jeśli marker idzie w górę, to jest bieg”. On sam uczył się zależności na podstawie przykładów.

Najważniejsze rzeczy do powiedzenia

- Testowano 7 konfiguracji.
- Parametry: okno, krok, warstwy LSTM.
- 7 konfiguracji $\times$ 3 zadania = 21 modeli.
- Okno = liczba klatek analizowanych naraz.
- Krok = przesunięcie między oknami.
- Więcej warstw/jednostek = większa pojemność modelu.
- Trening polegał na minimalizowaniu błędu predykcji.

Możliwe pytania i odpowiedzi

Pytanie: Co oznacza model `w50-L64` ?

Odpowiedź:

Oznacza model, który analizuje okna o długości 50 klatek i ma warstwę LSTM z 64 jednostkami.

Pytanie: Co oznacza `w10-L15x2` ?

Odpowiedź:

To model z oknem 10 klatek i dwiema warstwami LSTM, każda po 15 jednostek.

Pytanie: Czy większe okno zawsze daje lepszy wynik?

Odpowiedź:

Nie zawsze. Większe okno daje modelowi więcej kontekstu czasowego, ale może też zwiększyć trudność uczenia i ryzyko przeuczenia. W wynikach widać, że najlepsza konfiguracja zależała od zadania i poziomu oceny.

Pytanie: Co daje krok mniejszy od okna?

Odpowiedź:

Dzięki temu okna nachodzą na siebie. Model widzi więcej fragmentów ruchu, a każdy fragment jest przesunięty względem poprzedniego. To zwiększa liczbę przykładów treningowych.

Slajd 6 — Ewaluacja

Co powiedzieć

Wyniki ocenialiśmy na dwóch poziomach: poziomie okna i poziomie nagrania.

Poziom okna oznacza, że model klasyfikuje pojedynczy fragment sekwencji. Na przykład jeśli okno ma 50 klatek, model podejmuje decyzję tylko na podstawie tego fragmentu.

Poziom nagrania oznacza, że najpierw klasyfikujemy wszystkie okna pochodzące z danego nagrania, a potem łączymy te predykcje w jedną decyzję. U nas robiliśmy to przez modę, czyli wybieraliśmy klasę najczęściej przewidywaną przez model w oknach danego nagrania.

Główną metryką rankingową było F1-macro. F1 łączy precision i recall.

Precision mówi, jaka część przykładów przewidzianych jako dana klasa naprawdę należała do tej klasy.

Recall mówi, jaka część przykładów danej klasy została poprawnie odnaleziona przez model.

F1 jest średnią harmoniczną precision i recall. Jest użyteczne, gdy chcemy równoważyć oba te aspekty.

F1-macro oznacza, że F1 liczymy osobno dla każdej klasy, a potem uśredniamy wyniki. Dzięki temu każda klasa ma taki sam wpływ na wynik końcowy, niezależnie od tego, ile ma przykładów.

Różnica między accuracy i F1

Accuracy to po prostu odsetek poprawnych predykcji. Jeśli model ma 100 przykładów i 90 zaklasyfikuje dobrze, accuracy wynosi 90%.

Problem w tym, że przy nierównych klasach accuracy może być mylące. Jeśli jedna klasa dominuje, model może mieć wysokie accuracy, nawet jeśli słabo rozpoznaje mniejsze klasy.

Dlatego użyliśmy F1-macro, bo ona lepiej pokazuje, jak model radzi sobie ze wszystkimi klasami.

Najważniejsze rzeczy do powiedzenia

- Ocena była na poziomie okna i nagrania.
- Wynik nagrania powstaje przez agregację predykcji okien.
- Accuracy = procent poprawnych predykcji.
- Precision = ile przewidzianych pozytywów było poprawnych.
- Recall = ile prawdziwych przykładów klasy znaleziono.
- F1 łączy precision i recall.
- F1-macro uśrednia F1 po klasach.
- F1-macro jest lepsze przy nierównowadze klas.

Możliwe pytania i odpowiedzi

Pytanie: Czym dokładnie jest F1?

Odpowiedź:

F1 to metryka łącząca precision i recall. Jest wysoka tylko wtedy, gdy model ma zarówno dobrą precyzję, jak i dobry recall. Czyli model nie tylko rzadko myli daną klasę z innymi, ale też dobrze odnajduje przykłady tej klasy.

Pytanie: Dlaczego F1-macro, a nie samo accuracy?

Odpowiedź:

Ponieważ F1-macro traktuje wszystkie klasy równoważnie. Przy większej liczbie klas albo nierównych licznosciach klas accuracy może ukrywać problemy z rozpoznawaniem mniej licznych klas.

Pytanie: Co oznacza wynik na poziomie nagrania?

Odpowiedź:

To jedna końcowa decyzja dla całego pliku/nagrania. Najpierw model klasyfikuje wiele okien z tego nagrania, a potem wybieramy klasę, która pojawiała się najczęściej.

Pytanie: Dlaczego agregacja przez modę może poprawiać wynik?

Odpowiedź:

Bo pojedyncze okno może być błędnie sklasyfikowane, ale jeśli większość okien z nagrania jest poprawna, końcowa decyzja dla całego nagrania też będzie poprawna.

Pytanie: Czy agregacja przez modę zawsze poprawia wynik?

Odpowiedź:

Nie. Jeśli model systematycznie myli okna z danego nagrania, to moda może utrwalić błędną decyzję. Wtedy wynik na poziomie nagrania może być gorszy niż na poziomie okna.

Slajd 7 — Podsumowanie wyników

Co powiedzieć

Na tym slajdzie pokazujemy zbiorcze wyniki dla trzech zadań.

Dla typu chodu najlepszy wynik na poziomie okna uzyskał model `w50-L64`, czyli model z oknem 50 klatek i 64 jednostkami LSTM. Wynik na poziomie okna wyniósł 76,3%.

Na poziomie całego nagrania najlepszy był model `w20-L32`, który osiągnął 84,0%. To pokazuje, że model najlepszy dla pojedynczych okien nie zawsze musi być najlepszy po agregacji do poziomu nagrania.

Dla płci wyniki były bliskie 100% dla wszystkich konfiguracji.

Dla identyfikacji uczestnika najlepsze modele również osiągały prawie 100% lub 100%. To wygląda bardzo dobrze, ale jednocześnie wymaga ostrożnej interpretacji, bo może wynikać z tego, że model nauczył się cech konkretnego uczestnika albo nagrania.

Najbardziej uniwersalnym modelem był `w50-L64`, bo osiągał bardzo dobre wyniki w wielu zadaniach.

Najważniejsze rzeczy do powiedzenia

- Typ chodu był najtrudniejszy.
- Płeć i ID miały wyniki bliskie 100%.
- Najlepszy model zależy od poziomu oceny.
- `w50-L64` był najbardziej uniwersalny.
- 100% dla płci i ID wymaga ostrożności.

Możliwe pytania i odpowiedzi

Pytanie: Dlaczego typ chodu miał niższy wynik niż płeć i ID?

Odpowiedź:

Typ chodu może być bardziej zmienny. Różnice między klasami ruchu bywają subtelne, a ten sam uczestnik może wykonywać różne typy ruchu w podobny sposób. Natomiast płeć i ID mogą być mocno powiązane z proporcjami ciała i indywidualnym stylem ruchu.

Pytanie: Który model finalnie byście wybrali?

Odpowiedź:

Jako model uniwersalny wybralibyśmy `w50-L64`, bo był stabilny i bardzo dobry w kilku zadaniach. Natomiast dla klasyfikacji całych nagrań typu chodu najlepszy był `w20-L32`.

Slajd 8 — Wyniki: typ chodu

Co powiedzieć

Ten slajd pokazuje wyniki dla klasyfikacji typu chodu.

To było najtrudniejsze zadanie w projekcie. Najlepszy wynik na poziomie nagrania wyniósł 84,0% dla modelu `w20-L32`.

Widać, że wyniki na poziomie nagrania są lepsze niż wyniki na poziomie pojedynczego okna. To ma sens, ponieważ pojedynczy fragment ruchu może być niejednoznaczny, ale całe nagranie daje więcej informacji. Agregacja predykcji wielu okien pozwala ograniczyć wpływ pojedynczych błędów.

Dłuższe okna, takie jak 50 klatek, dobrze działały na poziomie okna, bo dawały modelowi więcej kontekstu czasowego. Z kolei przy klasyfikacji całych nagrań dobrze wypadł model z oknem 20 klatek.

Najważniejsze rzeczy do powiedzenia

- Typ chodu był najtrudniejszy.
- Najlepszy wynik na nagraniu: 84,0%.
- Wynik na nagraniu może być lepszy dzięki agregacji.
- Dłuższe okno daje więcej kontekstu, ale nie zawsze wygrywa globalnie.

Możliwe pytania i odpowiedzi

Pytanie: Dlaczego klasyfikacja typu chodu jest trudniejsza?

Odpowiedź:

Bo różnice między typami ruchu mogą być subtelne, zwłaszcza między podobnymi prędkościami chodu. Dodatkowo różni uczestnicy mogą wykonywać ten sam typ ruchu w indywidualny sposób.

Pytanie: Dlaczego w20-L32 wygrał na poziomie nagrania?

Odpowiedź:

Prawdopodobnie dawał dobry kompromis między długością kontekstu a prostotą modelu. Okno 20 klatek obejmuje wystarczający fragment ruchu, ale nie jest tak długie, żeby utrudniać uczenie.

Slajd 9 — Wyniki: płeć

Co powiedzieć

Ten slajd pokazuje wyniki dla rozpoznawania płci uczestnika.

Wszystkie konfiguracje osiągnęły wynik bliski 100%. Oznacza to, że model bardzo łatwo rozróżniał te klasy na podstawie danych markerów.

Możliwa interpretacja jest taka, że dane motion capture zawierają nie tylko informację o ruchu, ale też pośrednio informację o budowie ciała. Różnice w proporcjach, wysokości markerów, zakresie ruchu albo sposobie poruszania się mogły być wystarczająco charakterystyczne dla modelu.

Trzeba jednak uważać, żeby nie interpretować tego jako dowodu, że model ogólnie zawsze rozpoznaje płeć na podstawie ruchu. To jest wynik dla konkretnego zbioru danych i konkretnego sposobu podziału train/test.

Najważniejsze rzeczy do powiedzenia

- Wyniki dla płci były bliskie 100%.
- Model prawdopodobnie korzystał z cech anatomicznych i ruchowych.
- Wynik jest bardzo wysoki, więc wymaga ostrożności.
- Potrzebna byłaby walidacja na nowych uczestnikach.

Możliwe pytania i odpowiedzi

Pytanie: Czy to oznacza, że płeć zawsze da się rozpoznać z ruchu?

Odpowiedź:

Nie można tego tak uogólniać. To oznacza, że w naszym zbiorze i przy naszym podziale danych model bardzo dobrze rozróżniał klasy. Dla pełniejszej oceny trzeba byłoby przetestować model na zupełnie nowych uczestnikach.

Pytanie: Czy model mógł uczyć się wzrostu albo proporcji ciała?

Odpowiedź:

Tak, to jest możliwe. Dane markerów mogą zawierać informacje o proporcjach ciała, a nie tylko o samej dynamice ruchu.

Slajd 10 — Wyniki: identyfikacja uczestnika

Co powiedzieć

Ten slajd pokazuje wyniki dla identyfikacji konkretnego uczestnika.

Najlepsze modele osiągnęły 100% na poziomie nagrania. Oznacza to, że dla tych konfiguracji model potrafił przypisać całe nagranie do właściwej osoby.

Jednocześnie to zadanie jest szczególnie podatne na interpretację związaną z overfittingiem. Jeżeli dane tego samego uczestnika występują zarówno w treningu, jak i w teście, model może nauczyć się bardzo specyficznych cech tej osoby. Mogą to być proporcje ciała, sposób ustawienia markerów, charakterystyczna długość kroku albo ogólny styl poruszania się.

Dlatego wynik 100% jest ciekawy, ale niekoniecznie oznacza, że model dobrze poradziłby sobie z identyfikacją w zupełnie nowych warunkach lub przy nowych sesjach pomiarowych.

Najważniejsze rzeczy do powiedzenia

- Najlepsze modele osiągnęły 100%.
- Zadanie może być łatwe, jeśli model widzi dane tych samych osób w treningu i teście.
- Wynik może oznaczać uczenie się indywidualnych sygnatur.
- Potrzebna jest walidacja typu `participant_holdout` albo `session_holdout`.

Możliwe pytania i odpowiedzi

Pytanie: Czy 100% oznacza, że model jest idealny?

Odpowiedź:

Nie. Oznacza, że w naszym eksperymencie i przy naszym podziale danych model osiągnął 100%. Nie musi to oznaczać idealnej generalizacji na nowe osoby albo nowe warunki pomiaru.

Pytanie: Dlaczego słabsze modele miały duże spadki?

Odpowiedź:

Prawdopodobnie miały za małą pojemność albo nie potrafiły stabilnie uchwycić wzorców charakterystycznych dla uczestników. Przy identyfikacji osoby subtelne różnice w ruchu i budowie ciała mogą wymagać odpowiedniej długości okna i odpowiedniej liczby jednostek LSTM.

Slajd 11 — Interpretacja: możliwy overfitting

Co powiedzieć

Na tym slajdzie pokazujemy najważniejsze ograniczenie interpretacyjne naszego projektu.

Wyniki 100% dla płci i ID uczestnika są bardzo wysokie. Z jednej strony pokazują, że model potrafi znaleźć silne wzorce w danych. Z drugiej strony mogą sugerować przeuczenie albo zbyt łatwy podział danych.

Użyty podział `within_participant` oznacza, że dane tego samego uczestnika mogą występować zarówno w zbiorze treningowym, jak i testowym. W takim przypadku model może nauczyć się cech uczestnika, a nie tylko ogólnych wzorców, które przenosiłyby się na nowe osoby.

Dla mocniejszej weryfikacji należałoby użyć podziału `participant_holdout`, czyli takiego, w którym część uczestników jest całkowicie niewidoczna podczas treningu i pojawia się dopiero w teście.

Można też sprawdzić `session_holdout`, czyli trening na jednej sesji, a test na innej sesji. To pokazałoby, czy model jest odporny na zmianę warunków pomiarowych.

Najważniejsze rzeczy do powiedzenia

- 100% wyników trzeba interpretować ostrożnie.
- `within_participant` może ułatwiać zadanie.
- Model może uczyć się sygnatury uczestnika.
- Lepsza walidacja: `participant_holdout` albo `session_holdout`.
- To nie unieważnia wyników, ale pokazuje ograniczenie eksperymentu.

Możliwe pytania i odpowiedzi

Pytanie: Czy wasz model jest przeuczony?

Odpowiedź:

Nie możemy tego stwierdzić jednoznacznie tylko na podstawie tych wyników, ale bardzo wysokie wyniki dla płci i ID sugerują, że trzeba to sprawdzić. Najlepszym testem byłyby podział, w którym osoby z testu nie występują w treningu.

Pytanie: Czy `within_participant` jest błędnym podziałem?

Odpowiedź:

Nie jest błędny, ale odpowiada na inne pytanie. Sprawdza, czy model potrafi klasyfikować fragmenty i nagrania osób, które zna z treningu. Jeśli chcemy sprawdzić generalizację na nowe osoby, potrzebny jest `participant_holdout`.

Pytanie: Czy overfitting dotyczy też typu chodu?

Odpowiedź:

Może, ale w wynikach typu chodu nie widać tak skrajnie wysokich wartości. To zadanie było trudniejsze i bardziej realistycznie pokazuje ograniczenia modelu.

Slajd 12 — Macierze pomyłek: typ chodu i płec

Co powiedzieć

Macierz pomyłek pokazuje, jak model myli poszczególne klasy.

Wiersze zwykle odpowiadają klasom rzeczywistym, a kolumny klasom przewidzianym przez model. Elementy na przekątnej oznaczają poprawne klasyfikacje. Im większe wartości na przekątnej, tym lepiej. Wartości poza przekątną pokazują błędy, czyli przypadki, w których model pomylił jedną klasę z inną.

Dla typu chodu macierz pomyłek pozwala zobaczyć, które typy ruchu były najczęściej mylone. To jest ważniejsze niż samo accuracy, bo możemy zobaczyć strukturę błędów. Na przykład model może dobrze odróżniać bieg od chodu, ale mylić chód wolny z komfortowym.

Dla płci macierz powinna mieć bardzo silną przekątną, ponieważ wyniki były bliskie 100%. To oznacza, że model prawie nie popełniał błędów w tym zadaniu.

Najważniejsze rzeczy do powiedzenia

- Macierz pomyłek pokazuje błędy między klasami.
- Przekątna = dobre predykcje.
- Poza przekątną = pomyłki.
- Dla typu chodu można zobaczyć, które klasy są podobne.
- Dla płci prawie wszystko powinno być na przekątnej.

Możliwe pytania i odpowiedzi

Pytanie: Co pokazuje macierz pomyłek?

Odpowiedź:

Pokazuje, ile przykładów danej klasy zostało przypisanych do każdej możliwej klasy. Dzięki temu widać nie tylko liczbę błędów, ale też ich typ.

Pytanie: Dlaczego macierz pomyłek jest lepsza niż jedna liczba accuracy?

Odpowiedź:

Bo accuracy mówi tylko, jaki procent predykcji był poprawny. Macierz pomyłek pokazuje, które klasy są mylone ze sobą, więc daje więcej informacji diagnostycznej.

Pytanie: Co oznacza dobra macierz pomyłek?

Odpowiedź:

Dobra macierz ma wysokie wartości na przekątnej i niskie wartości poza przekątną.

Slajd 13 — Macierze pomyłek: ID uczestnika

Co powiedzieć

Na tym slajdzie pokazujemy macierz pomyłek dla identyfikacji uczestnika.

W tym zadaniu liczba klas jest większa, bo każda osoba jest osobną klasą. Dlatego macierz jest bardziej rozbudowana niż dla płci.

Jeśli najlepsze modele osiągały wynik bliski 100%, to w macierzy powinniśmy widzieć dominującą przekątną. Oznacza to, że nagrania danego uczestnika były przypisywane do właściwego ID.

Jeżeli pojawiają się wartości poza przekątną, oznacza to, że model pomylił jednego uczestnika z innym. Takie błędy mogą wynikać z podobnego stylu ruchu, podobnych proporcji ciała albo zbyt małej ilości danych dla danej osoby.

Warto podkreślić, że ta macierz wygląda bardzo dobrze, ale wciąż obowiązuje wcześniejsze zastrzeżenie: wynik trzeba sprawdzić na bardziej wymagającym podziale danych.

Najważniejsze rzeczy do powiedzenia

- ID uczestnika = wiele klas.
- Przekątna oznacza poprawną identyfikację osób.
- Błędy poza przekątną oznaczają pomylenie uczestników.
- Bardzo dobre wyniki trzeba interpretować razem z ryzykiem overfittingu.

Możliwe pytania i odpowiedzi

Pytanie: Dlaczego macierz dla ID jest większa?

Odpowiedź:

Bo każda osoba jest osobną klasą. Jeśli mamy wielu uczestników, macierz ma dużo wierszy i kolumn.

Pytanie: Co oznacza pomylenie dwóch uczestników?

Odpowiedź:

Oznacza, że model uznał nagranie jednej osoby za nagranie innej osoby. Może to wynikać z podobieństwa wzorca ruchu albo z ograniczeń modelu.

Slajd 14 — Wnioski

Co powiedzieć

Podsumowując, LSTM dobrze sprawdził się w klasyfikacji sekwencji motion capture.

Najtrudniejszym zadaniem było rozpoznawanie typu chodu. Wyniki były tam niższe niż dla płci i identyfikacji uczestnika, co sugeruje, że klasy ruchu są bardziej złożone i mniej jednoznaczne.

Agregacja okien do poziomu nagrania często poprawiała wynik, ponieważ końcowa decyzja była oparta na wielu fragmentach sekwencji, a nie na pojedynczym oknie.

Najbardziej uniwersalnym modelem okazał się `w50-L64`, choć dla całych nagrań typu chodu najlepszy był `w20-L32`.

Najważniejszym ograniczeniem projektu jest sposób podziału danych. Wyniki 100% dla płci i ID uczestnika wymagają dalszej weryfikacji na bardziej rygorystycznym podziale, na przykład `participant_holdout`.

Jako dalszy krok zaproponowalibyśmy przetestowanie modeli na nowych uczestnikach oraz sprawdzenie, czy model zachowuje jakość przy zmianie sesji pomiarowej.

Najważniejsze rzeczy do powiedzenia

- LSTM nadaje się do danych motion capture.
- Typ chodu był najtrudniejszy.
- Agregacja okien zwykle pomaga.
- `w50-L64` był najbardziej uniwersalny.
- Trzeba sprawdzić generalizację na nowych uczestnikach.
- 100% wyników nie należy interpretować bezkrytycznie.

Możliwe pytania i odpowiedzi

Pytanie: Jaki jest główny wniosek z projektu?

Odpowiedź:

Sieć LSTM potrafi skutecznie klasyfikować sekwencje motion capture, ale sposób walidacji ma duży wpływ na interpretację wyników.

Pytanie: Co zrobilibyście dalej?

Odpowiedź:

Przetestowalibyśmy model w bardziej wymagającym scenariuszu, na przykład z podziałem `participant_holdout`, gdzie osoby testowe nie pojawiają się w treningu. Sprawdzilibyśmy też odporność na zmianę sesji.

Pytanie: Czy projekt zakończył się sukcesem?

Odpowiedź:

Tak, bo udało się przygotować pipeline, wytrenować wiele konfiguracji modeli i uzyskać wysokie wyniki. Jednocześnie projekt pokazał ważne ograniczenie związane z generalizacją.

Slajd 15 — Literatura i źródła

Co powiedzieć

Na końcu pokazujemy źródła, na których opierał się projekt.

Pierwsze źródło dotyczy użycia LSTM do automatycznej klasyfikacji danych motion capture. To był punkt odniesienia dla naszego podejścia.

Drugie źródło to zbiór danych Riglet et al. z 2024 roku, z którego korzystaliśmy w projekcie. Zawiera on dane motion capture zdrowych młodych dorosłych wykonujących chód i bieg w różnych warunkach.

Najważniejsze rzeczy do powiedzenia

- Jedno źródło dotyczy metody LSTM dla motion capture.
- Drugie źródło dotyczy zbioru danych.
- Nasz projekt łączył dane motion capture z klasyfikacją sekwencyjną.

Możliwe pytania i odpowiedzi

Pytanie: Czy korzystaliście z gotowego modelu z literatury?

Odpowiedź:

Nie wprost. Literatura była punktem odniesienia, ale trenowaliśmy własne konfiguracje modeli na wybranym zbiorze danych.

Pytanie: Czy dane były publiczne?

Odpowiedź:

Tak, korzystaliśmy z opublikowanego zbioru danych opisanego w artykule Scientific Data.

4. Krótkie wyjaśnienia pojęć, które trzeba znać

Czym jest LSTM?

LSTM to typ rekurencyjnej sieci neuronowej przeznaczony do analizy sekwencji. W przeciwieństwie do zwykłej sieci neuronowej, LSTM uwzględnia kolejność danych i przechowuje informację o poprzednich krokach w specjalnym stanie pamięci.

W naszym projekcie LSTM analizuje kolejne klatki ruchu. Dzięki temu może wykrywać wzorce typu: jak zmienia się pozycja nóg, miednicy i tułowia w czasie.

Jak działa LSTM?

LSTM przetwarza sekwencję krok po kroku. W każdym kroku dostaje aktualną klatkę oraz informację zapamiętaną z wcześniejszych klatek.

Ma trzy główne bramki:

- **forget gate** — decyduje, co usunąć z pamięci,
- **input gate** — decyduje, co dopisać do pamięci,
- **output gate** — decyduje, co przekazać dalej.

Dzięki temu LSTM może przechowywać ważne informacje przez dłuższy czas i ignorować informacje mniej istotne.

Jak trenowaliśmy LSTM?

Trening polegał na pokazaniu modelowi wielu przykładów okien ruchu wraz z etykietami. Model przewidywał klasę, porównywał predykcję z prawdziwą etykietą, a następnie aktualizował swoje wagi, żeby zmniejszyć błąd.

W uproszczeniu:

1. wejście: okno ruchu,
 2. predykcja: prawdopodobieństwa klas,
 3. porównanie z prawdziwą etykietą,
 4. obliczenie błędu,
 5. aktualizacja wag,
 6. powtarzanie przez kolejne epoki.
-

Co to jest okno?

Okno to fragment sekwencji składający się z określonej liczby kolejnych klatek.

Przykład:

- **w20** oznacza okno 20 klatek,
- **w50** oznacza okno 50 klatek,
- **w100** oznacza okno 100 klatek.

Przy częstotliwości 100 Hz:

- 20 klatek to około 0,2 sekundy,
 - 50 klatek to około 0,5 sekundy,
 - 100 klatek to około 1 sekunda.
-

Co to jest krok?

Krok to przesunięcie między kolejnymi oknami.

Przykład:

Jeśli okno ma 50 klatek, a krok wynosi 25, to pierwsze okno obejmuje klatki 1–50, drugie 26–75, trzecie 51–100 itd.

Mniejszy krok oznacza większe nakładanie okien i więcej przykładów treningowych.

Co oznaczają warstwy LSTM?

Warstwy LSTM określają strukturę modelu.

Przykłady:

- L15 — jedna warstwa LSTM z 15 jednostkami,
- L64 — jedna warstwa LSTM z 64 jednostkami,
- L15x2 — dwie warstwy LSTM po 15 jednostek,
- L64x32 — pierwsza warstwa ma 64 jednostki, druga 32.

Więcej jednostek i warstw zwiększa możliwości modelu, ale może też zwiększyć ryzyko overfittingu.

Co to jest accuracy?

Accuracy to odsetek poprawnych predykcji.

Jeśli model poprawnie zaklasyfikował 90 ze 100 przykładów, accuracy wynosi 90%.

Co to jest precision?

Precision mówi, jaka część przykładów przewidzianych jako dana klasa rzeczywiście należała do tej klasy.

Inaczej: jeśli model mówi „to jest klasa A”, precision mówi, jak często ma rację.

Co to jest recall?

Recall mówi, jaka część przykładów danej klasy została poprawnie odnaleziona.

Inaczej: jeśli mamy wszystkie prawdziwe przykłady klasy A, recall mówi, ile z nich model znalazł.

Co to jest F1?

F1 łączy precision i recall w jedną metrykę.

F1 jest wysokie tylko wtedy, gdy model ma jednocześnie dobre precision i dobre recall.

Co to jest F1-macro?

F1-macro liczy F1 osobno dla każdej klasy, a potem uśrednia wyniki.

Dzięki temu każda klasa ma taki sam wpływ na wynik końcowy, nawet jeśli klasy mają różną licznosc.

Co to jest macierz pomyłek?

Macierz pomyłek pokazuje, jak model klasyfikował przykłady poszczególnych klas.

- wiersze: klasy rzeczywiste,
- kolumny: klasy przewidziane,
- przekątna: poprawne predykcje,
- wartości poza przekątną: błędy.

Macierz pomyłek pozwala zobaczyć, które klasy są ze sobą mylone.

Różnica: poziom okna vs poziom nagrania

Poziom okna oznacza, że oceniamy predykcję dla pojedynczego fragmentu sekwencji.

Poziom nagrania oznacza, że bierzemy wiele okien z jednego nagrania i łączymy ich predykcje w jedną decyzję.

W naszym projekcie wynik nagrania wyznaczaliśmy przez modę, czyli wybór klasy najczęściej przewidywanej w oknach danego nagrania.

5. Najważniejsze pytania, które mogą paść na obronie/prezentacji

Pytanie 1: Dlaczego wybraliście LSTM?

Odpowiedź:

Ponieważ dane motion capture są sekwencją czasową. LSTM dobrze nadaje się do danych, w których

ważna jest kolejność i zależność między kolejnymi krokami. W naszym przypadku istotne jest nie tylko położenie markerów w jednej klatce, ale też ich zmiana w czasie.

Pytanie 2: Co oznacza okno czasowe?

Odpowiedź:

Okno czasowe to fragment nagrania składający się z określonej liczby kolejnych klatek. Model klasyfikuje takie okno jako jeden przykład.

Pytanie 3: Co oznacza krok?

Odpowiedź:

Krok określa, o ile klatek przesuwamy się przy tworzeniu kolejnego okna. Jeśli krok jest mniejszy niż długość okna, okna nakładają się na siebie.

Pytanie 4: Jak trenowaliście model?

Odpowiedź:

Dzieliśmy dane na okna, przypisywaliśmy im etykiety, a następnie trenowaliśmy LSTM do przewidywania klasy. Model minimalizował błąd klasyfikacji, a jego wagi były aktualizowane przez propagację wsteczną i optymalizator Adam.

Pytanie 5: Czym jest F1?

Odpowiedź:

F1 to metryka łącząca precision i recall. Jest szczególnie przydatna, gdy chcemy ocenić model nie tylko przez ogólną liczbę poprawnych predykcji, ale też przez jakość rozpoznawania poszczególnych klas.

Pytanie 6: Dlaczego użyliście F1-macro?

Odpowiedź:

Bo F1-macro traktuje każdą klasę równoważnie. To ważne, gdy klasy mogą mieć różne liczności albo gdy chcemy mieć pewność, że model nie ignoruje mniej licznych klas.

Pytanie 7: Co pokazuje macierz pomyłek?

Odpowiedź:

Pokazuje, które klasy model rozpoznaje poprawnie, a które myli ze sobą. Przekątna oznacza poprawne klasyfikacje, a wartości poza przekątną oznaczają błędy.

Pytanie 8: Dlaczego wynik na poziomie nagrania może być lepszy niż na poziomie okna?

Odpowiedź:

Bo pojedyncze okno może być błędne lub niejednoznaczne, ale całe nagranie zawiera wiele okien. Jeśli większość z nich jest sklasyfikowana dobrze, agregacja przez modę daje poprawną końcową decyzję.

Pytanie 9: Czy wyniki 100% oznaczają brak błędów modelu?

Odpowiedź:

Oznaczają brak błędów w danym eksperymencie i przy danym podziale danych. Nie oznaczają jednak, że model zawsze będzie działał idealnie na nowych osobach albo w nowych warunkach.

Pytanie 10: Co może sugerować overfitting?

Odpowiedź:

Bardzo wysokie wyniki, szczególnie 100% dla płci i identyfikacji uczestnika, mogą sugerować, że model nauczył się cech specyficznych dla uczestników lub nagrań, zamiast ogólnych wzorców.

Pytanie 11: Jak można lepiej sprawdzić generalizację modelu?

Odpowiedź:

Można zastosować `participant_holdout`, czyli podział, w którym uczestnicy z testu nie występują w treningu. Można też zastosować `session_holdout`, czyli trenować na jednej sesji, a testować na innej.

Pytanie 12: Który model był najlepszy?

Odpowiedź:

Najbardziej uniwersalny był `w50-L64`, ponieważ dobrze działał w kilku zadaniach. Natomiast dla klasyfikacji całych nagrań typu chodu najlepszy wynik uzyskał `w20-L32`.

6. Bardzo krótkie podsumowanie do nauczania się

W projekcie klasyfikowaliśmy dane motion capture, czyli sekwencje położenia markerów 3D opisujących ruch człowieka. Użyliśmy sieci LSTM, ponieważ dane mają charakter czasowy i ważna jest kolejność klatek.

Dane przetwarzaliśmy przez wczytanie CSV, centrowanie względem miednicy, standaryzację i podział na okna czasowe. Model dostawał okno jako tensor `(window, n_features)` i przewidywał klasę przez softmax.

Testowaliśmy 7 konfiguracji modeli i 3 zadania, czyli łącznie 21 modeli. Różnice między modelami dotyczyły długości okna, kroku i liczby jednostek/warstw LSTM.

Wyniki ocenialiśmy na poziomie okna i nagrania. Poziom okna to pojedynczy fragment sekwencji, a poziom nagrania to agregacja predykcji wielu okien przez modę. Główną metryką było F1-macro, ponieważ dobrze ocenia jakość klasyfikacji przy wielu klasach.

Najtrudniejsze było rozpoznawanie typu chodu. Płeć i ID uczestnika osiągały wyniki bliskie 100%, ale należy je interpretować ostrożnie, bo mogą wynikać z uczenia się indywidualnych cech uczestników. Najważniejszym dalszym krokiem byłaby walidacja na nowych uczestnikach, czyli `participant_holdout`.

7. Ostateczny podział ról

Osoba 1 — Wprowadzenie i LSTM

Slajdy:

1. Strona tytułowa
2. Cel projektu i dane
3. Pipeline i model
4. Zadania klasyfikacji

Co musi umieć najlepiej:

- wyjaśnić, czym jest motion capture,
- powiedzieć, jakie dane były wejściem,
- wyjaśnić pipeline przetwarzania,
- dokładnie opowiedzieć, czym jest LSTM,
- opowiedzieć, dlaczego LSTM pasuje do danych sekwencyjnych.

Najważniejsze zdanie tej osoby:

„LSTM wybraliśmy dlatego, że motion capture jest sekwencją czasową, a w ruchu ważne są zależności między kolejnymi klatkami, nie tylko pojedyncza pozycja ciała.”

Osoba 2 — Eksperyment, trening i metryki

Slajdy:

1. Eksperyment
2. Ewaluacja
3. Podsumowanie wyników

Co musi umieć najlepiej:

- wyjaśnić, czym jest okno,
- wyjaśnić, czym jest krok,
- wyjaśnić, czym są warstwy LSTM,
- opowiedzieć proces trenowania modelu,
- wyjaśnić accuracy, precision, recall, F1 i F1-macro,
- wyjaśnić różnicę między poziomem okna a poziomem nagrania.

Najważniejsze zdanie tej osoby:

„Wyniki ocenialiśmy na poziomie pojedynczego okna oraz całego nagrania, gdzie decyzję końcową uzyskiwaliśmy przez agregację predykcji okien.”

Osoba 3 — Wyniki, macierze pomyłek i wnioski

Slajdy:

1. Wyniki: typ chodu
2. Wyniki: płeć
3. Wyniki: identyfikacja uczestnika
4. Interpretacja: możliwy overfitting
5. Macierze pomyłek — typ chodu i płeć
6. Macierze pomyłek — ID uczestnika
7. Wnioski
8. Literatura i źródła

Co musi umieć najlepiej:

- omówić wyniki dla trzech zadań,
- powiedzieć, które zadanie było najtrudniejsze,
- wyjaśnić, co pokazuje macierz pomyłek,
- wyjaśnić, dlaczego 100% trzeba interpretować ostrożnie,
- opowiedzieć o możliwym overfittingu,
- zaproponować dalszą walidację.

Najważniejsze zdanie tej osoby:

„Najlepsze wyniki wyglądają bardzo dobrze, ale szczególnie dla płci i ID uczestnika trzeba je zweryfikować na podziale z nowymi uczestnikami, żeby sprawdzić realną generalizację modelu.”
